
YouTube
TRENDS
YouTube
YouTube
YouTube
YouTube
TRENDS
YouTube
TRENDS
YouTube
TRENDS
YouTube
TRENDONS
AUDIENCE
YouTube
DALL·E 2

Youtube Trends

Maggio 2024

Obiettivo:
L'obiettivo è studiare le relazioni tra i creators in tendenza su Youtube Italia (Maggio 2024) con gli altri creators della piattaforma e le rispettive audience.

1. ***Data Gathering***, collezionare i dati dei creators dalla piattaforma.
2. ***Collaboration Network Analysis***, analisi della rete delle collaborazioni.
3. ***Audience Network Analysis***, analisi della rete tra creators e audience.
4. ***Machine Learning*****,** predizione dei creators che potrebbero collaborare.

Data Gathering

- ***Google API***
- Libreria Python che mette a disposizione tutti i metodi necessari per eseguire le richieste

```python
# Google API
from googleapiclient.discovery import build

# Imposto le credenziali
DEVELOPER_KEY = credenziali["Build"]["DEVELOPER_KEY"]
YOUTUBE_API_SERVICE_NAME = credenziali["Build"]["YOUTUBE_API_SERVICE_NAME"]
YOUTUBE_API_VERSION = credenziali["Build"]["YOUTUBE_API_VERSION"]

# Creo il client
youtube = build(
                YOUTUBE_API_SERVICE_NAME,
                YOUTUBE_API_VERSION,
                developerKey=DEVELOPER_KEY
            )
```

Riepilogo dei Dati

Creators con almeno un video in tendenza : **104**

Per ogni creator sono stati estratti tutti i video caricati sulla piattaforma, cercando (tramite ***Regex***) nel titolo o nella descrizione un match ***@Handle*** che codifica una collaborazione.

Rete delle collaborazioni : **2032** Nodi, **5333** Archi

Ogni match trovato era una potenziale collaborazione.
Però alcuni di questi corrispondevano ad indirizzi mail, oppure a @handle non validi.
Durante l'estrazione delle audience è stato convalidato ciascun match e filtrarata la rete.

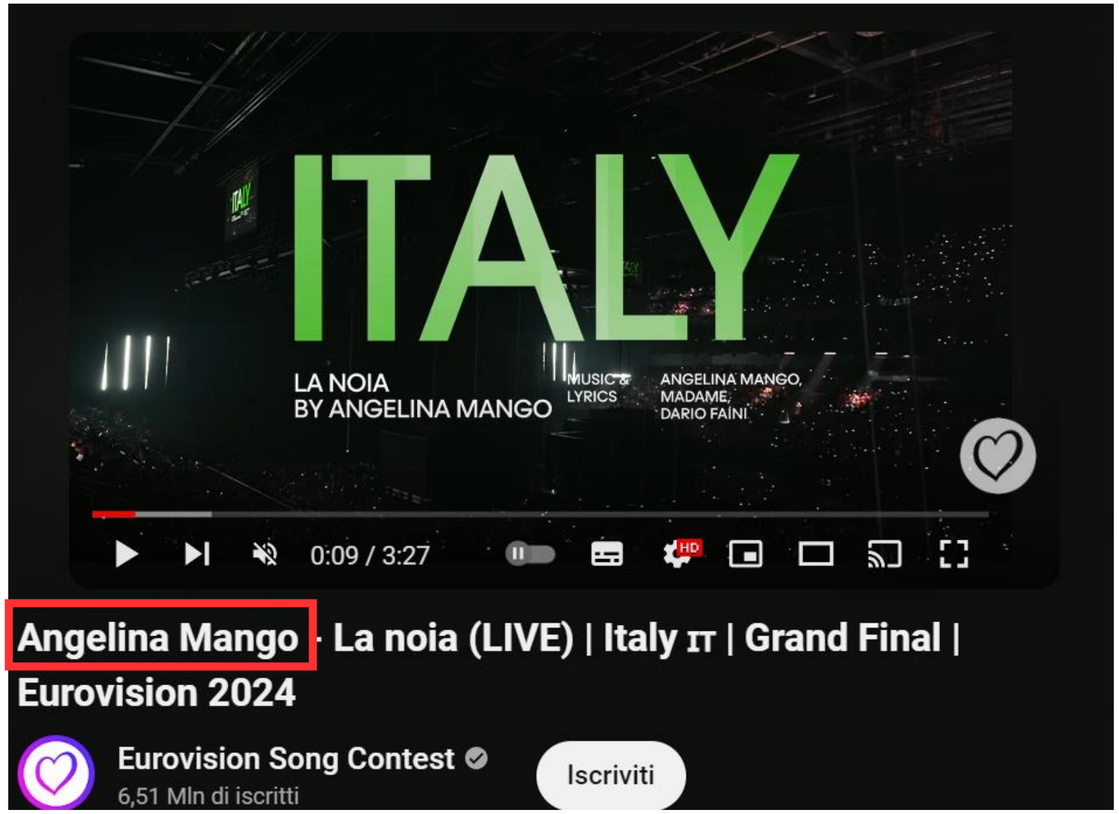
Rete Bipartita Creator-Commenters : **2 491 012** Nodi, **3 091 570** Archi

Per ogni creator della rete delle collaborazioni sono stati estratti i top-level commenter, per un massimo di 3000 user (soglia stabilita per l'analisi di audience overlapping)

Perdita di Informazione

L’unico modo per identificare le collaborazioni su Youtube è tramite la menzione @Handle.

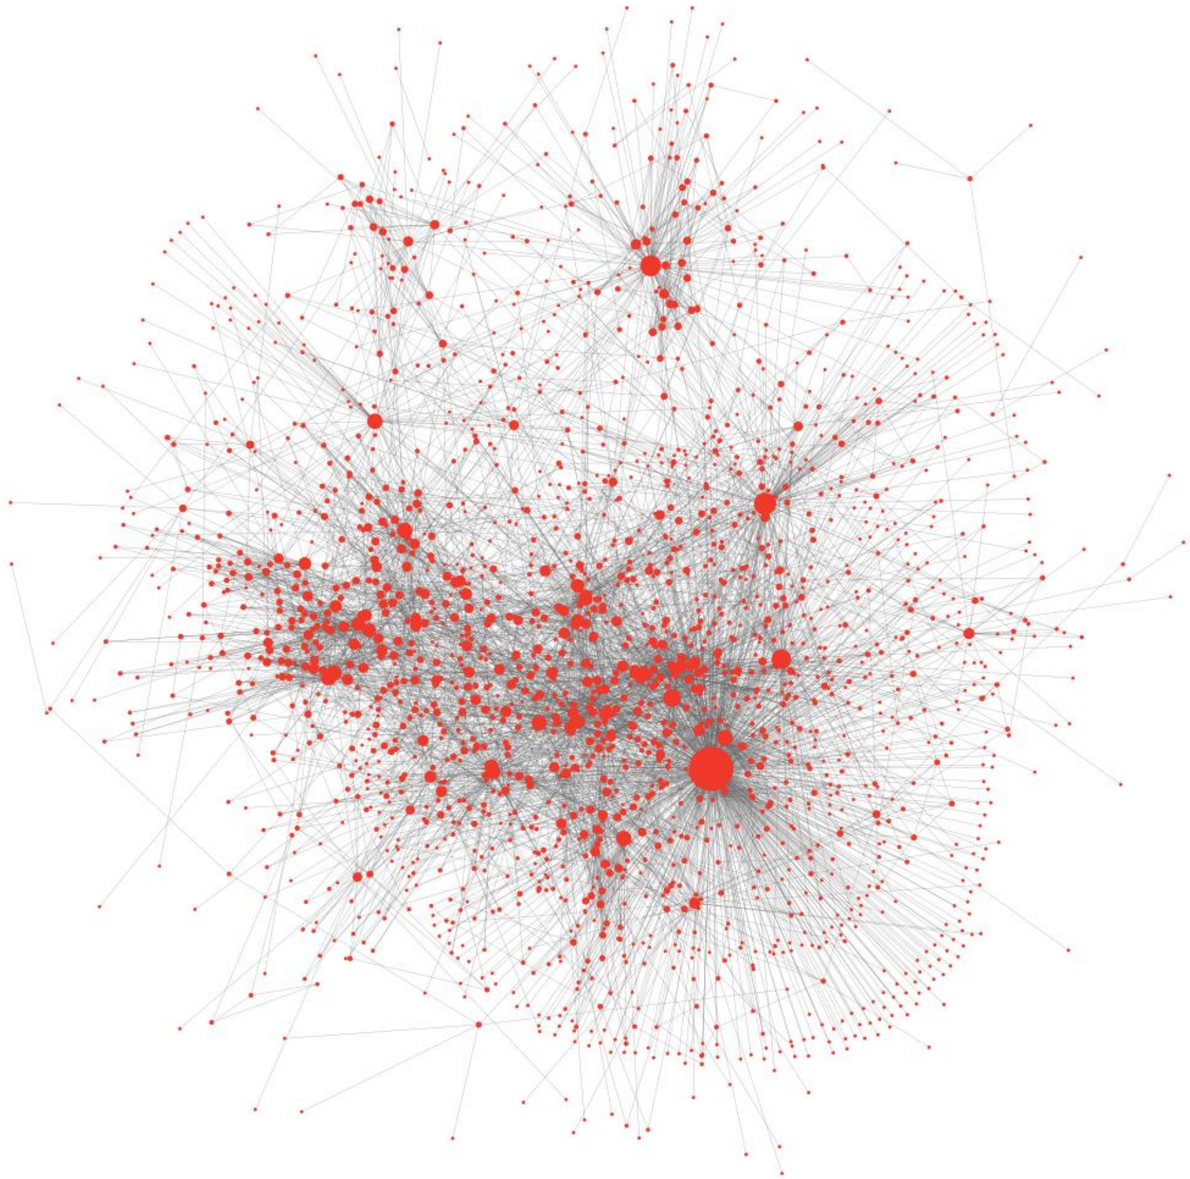
Ma spesso i creators collaborano tra loro senza menzionarsi utilizzandolo.



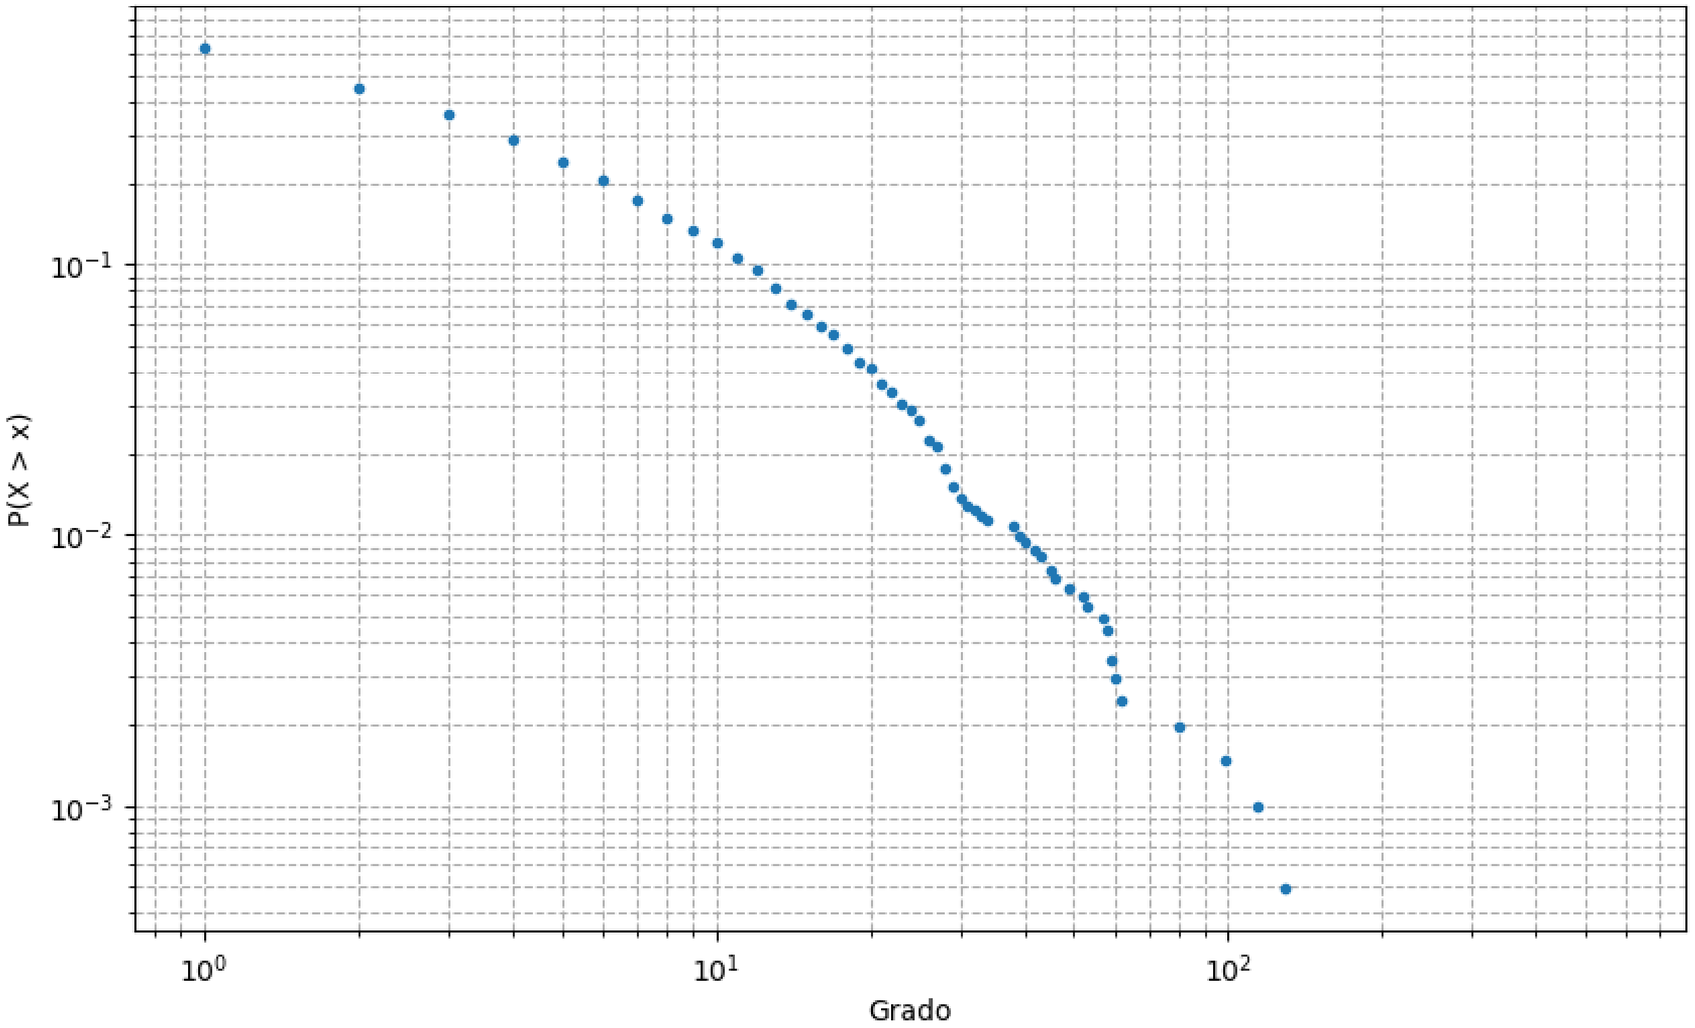


Collaboration Network

NODI	2032
ARCHI	5333
GRADO MEDIO	5.250
GRADO MINIMO	1
GRADO MASSIMO	569
DEVIAZIONE STANDARD GRADO	14.981
MEDIANA	2
DENSITA’	0.00258



ECCDF



- La maggior parte dei creators collabora con un numero limitato di altri creators.
- Pochi creators hanno un alto numero di collaborazioni.
- **Tipico delle reti sociali reali**.

Hub della Rete



@OmarESPN

[569]

@espndeportes

[80]



@EurovisionSongContest

[130]

@Houseofhighlights

[62]



@TiboInShape

[114]



@jakidale

[60]

@warnermusicitalia

[99]

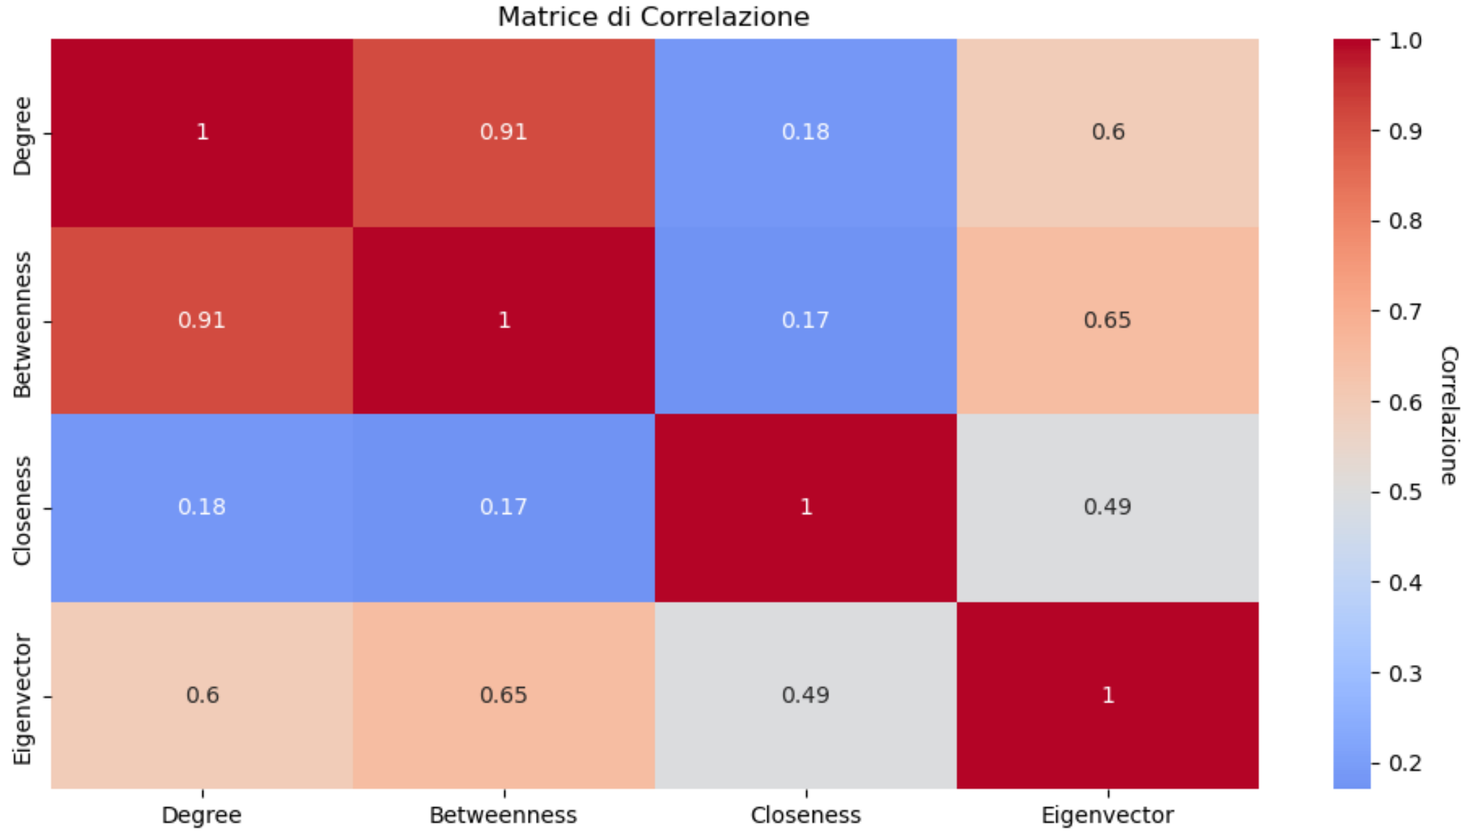


@petcollective

[59]

Centralità

Avere molte collaborazioni dirette, o fungere da intermediario, non implica necessariamente che un creator sia più vicino a tutti gli altri nodi della rete.



Bassa correlazione della ***Closeness Centrality*** con la ***Degree Centrality*** (0.18) e la ***Betweenness Centrality*** (0.17)

Connettività

COMPONENTI CONNESSE	8
COMPONENTE CONNESSA PIU' GRANDE	2013
GANDEZZA MEDIA DELLE ALTRE COMPONENTI ESCLUSE	2.714

Transitività

BRIDGES	752
LOCAL BRIDGES	1079
GLOBAL CLUSTERING COEFFICIENT	0.0508
TRIANGOLI	4246
AVG CLUSTERING COEFFICIENT	0.250

Assortatività (ordinale sul grado) = **- 0.123**

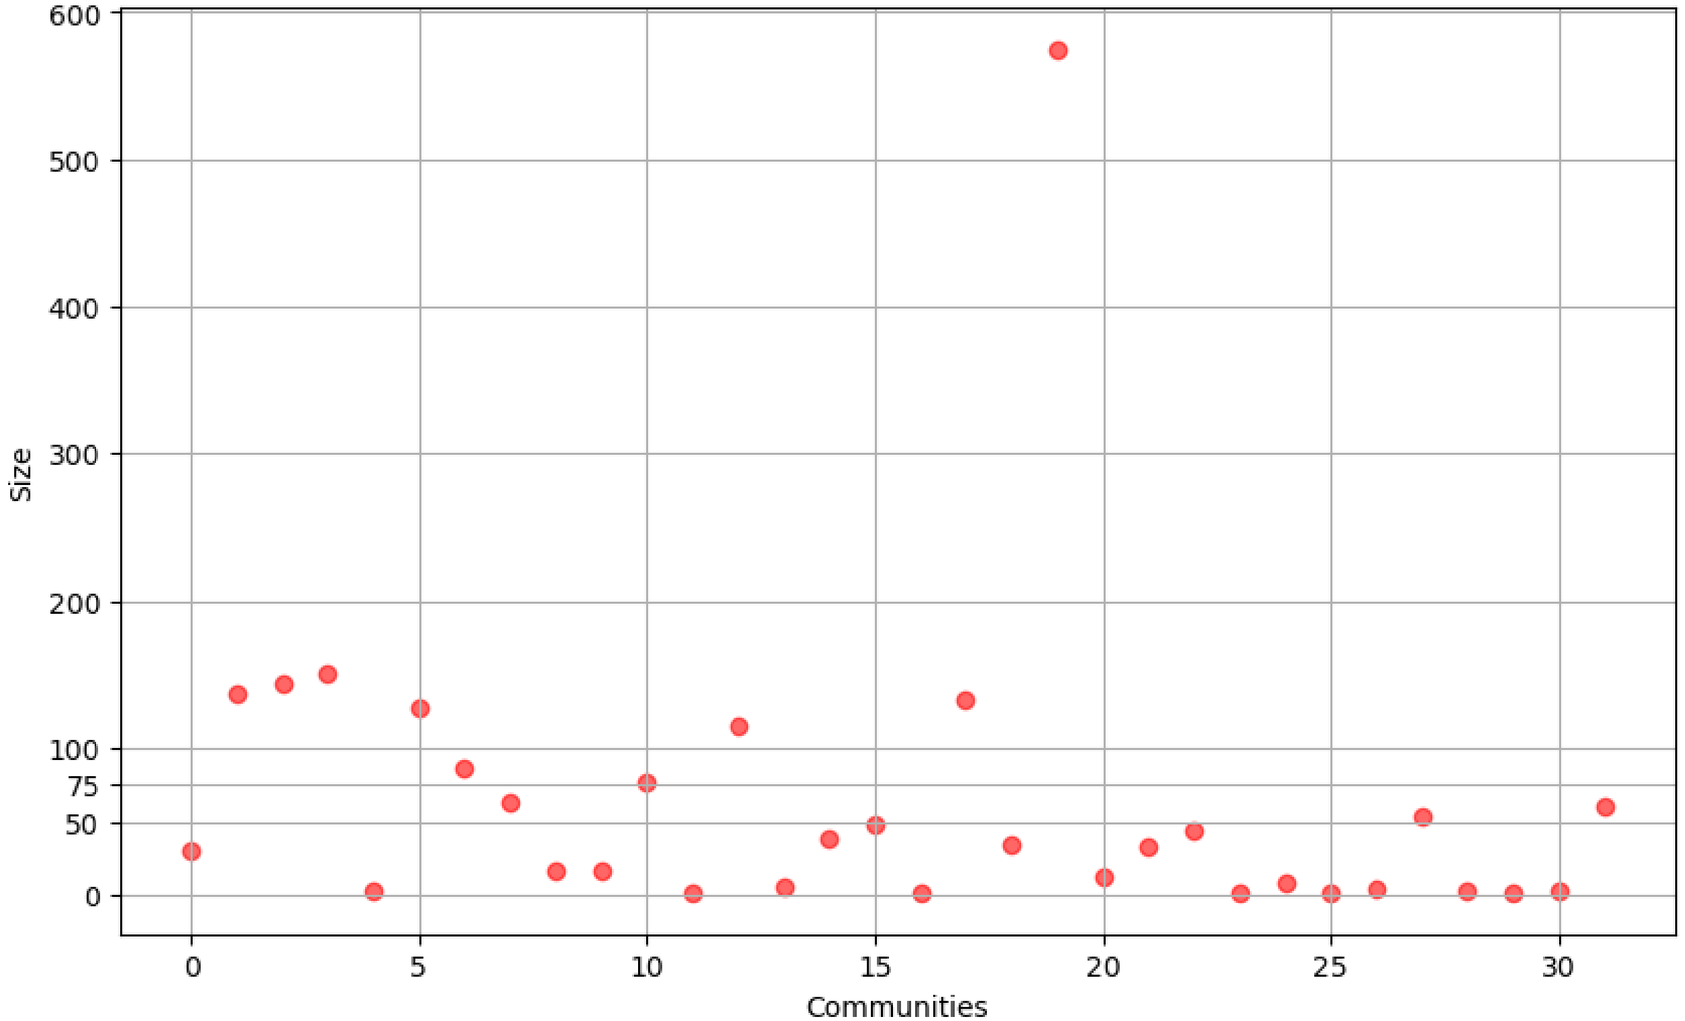
Leggermente ***disassortativa***.

Gli Hub tendono a collaborare con creators meno connessi.

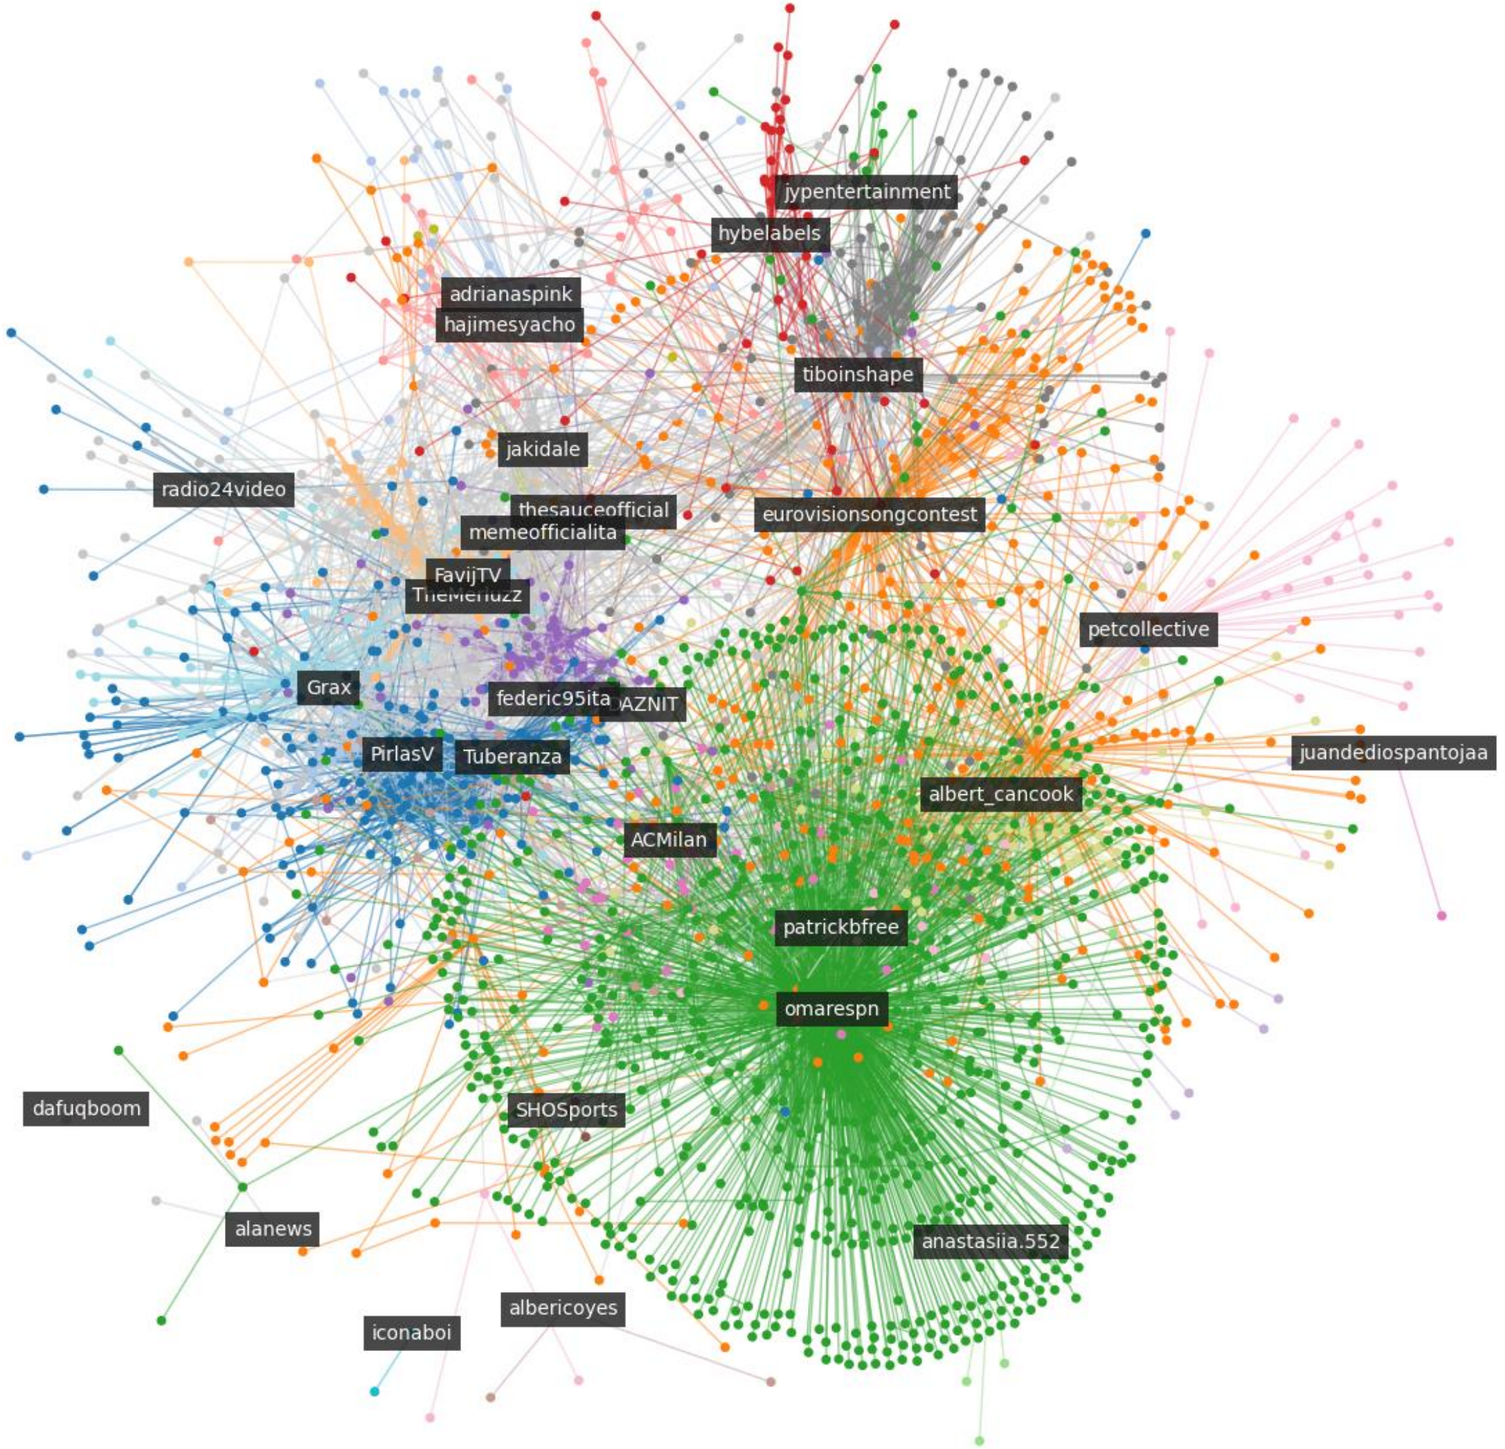
Per ampliare la loro audience, diversificando i contenuti.

Community Detection

Tramite l'***Algoritmo di Louvain*** sono state trovate **32** Comunità, per un valore di ***Modularità*** pari a **0.851**.



Community Size Plot



Rete delle Comunità

Con le etichette dei creators con grado maggiore per ogni comunità

Audience Network

NODI	2 491 012
ARCHI	3 091 570

Creator

NODI	2032
GRADO MEDIO	1502.950
GRADO MINIMO	1
GRADO MASSIMO	2866
DEVIAZIONE STANDARD GRADO	971.831

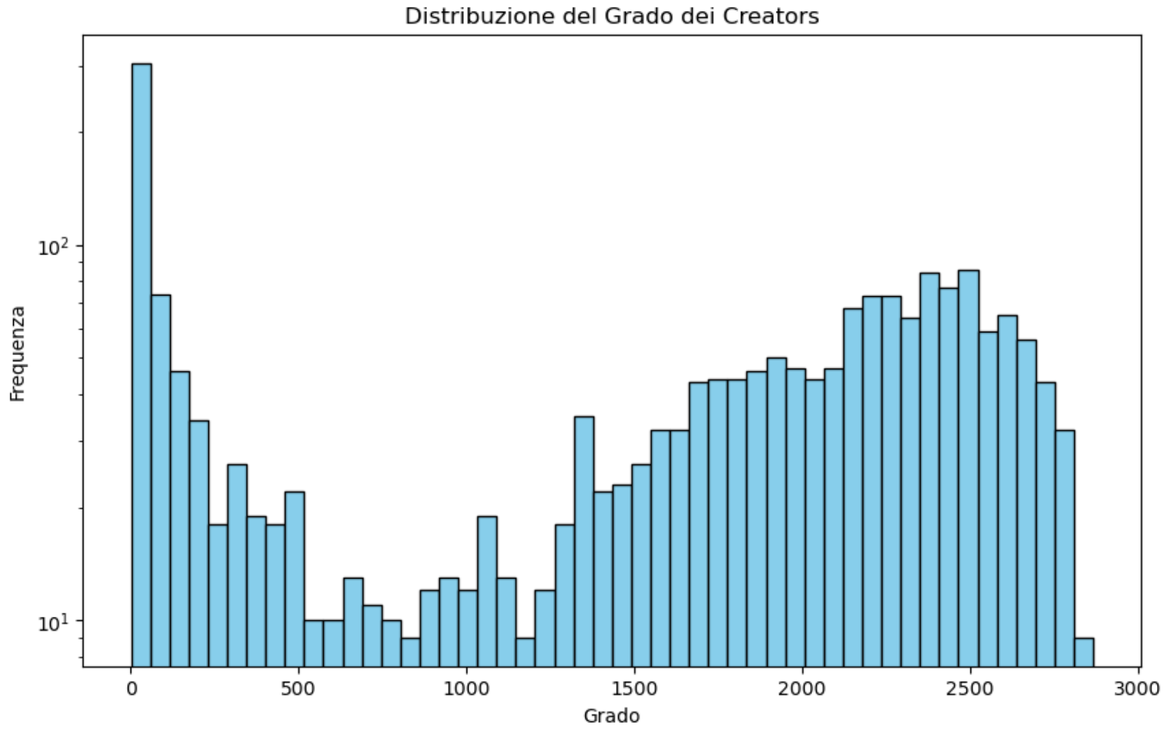
Commenter

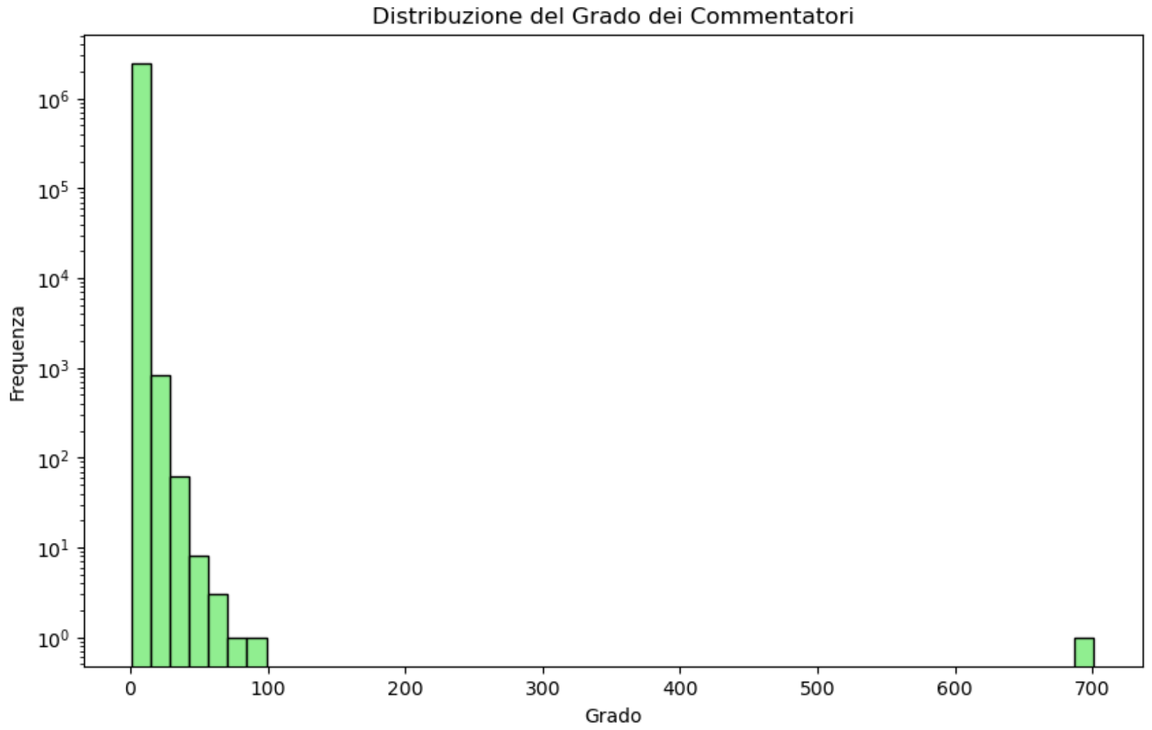
NODI	2 488 980
GRADO MEDIO	1.242
GRADO MINIMO	1
GRADO MASSIMO	701
DEVIAZIONE STANDARD GRADO	0.963

Audience Overlapping

Basso Audience Overlapping tra tutti i creators della rete.

- Alta SD del grado dei creators ma bassa SD del grado dei commenters. Grande variabilità nelle audience dei creators ed una bassa variabilità nel comportamento dei commenters.





Densità = 0.000604

La rete è ***globalmente sparsa***. (conforme al basso audience overlapping)

Connettività

171 componenti connesse di cui la più grande comprende **2 488 297** nodi ed un diametro approssimato = **12**.

Proseguiamo con due approssimazioni del calcolo:

- ***Rete Campionata*** (300 000 nodi): sottoinsieme (casuale) rappresentativo.
- ***Sottografi*** (20 000 nodi): comprende tutta la rete ma è meno preciso a causa dei nodi esclusi iterando sui sottografi.

Connettività

	Rete Campionata (300 000nodi)	*Sottografi (20 000 nodi)*
Avg Shortest Path	**7.736**	**4.4**
Clustering Bipartito	**0.128**	**0.953**

Il calcolo sulla rete campionata conferma che la rete è ***ben connessa*** ma con una bassa tendenza a formare triadi (due commenter connessi da un creator).

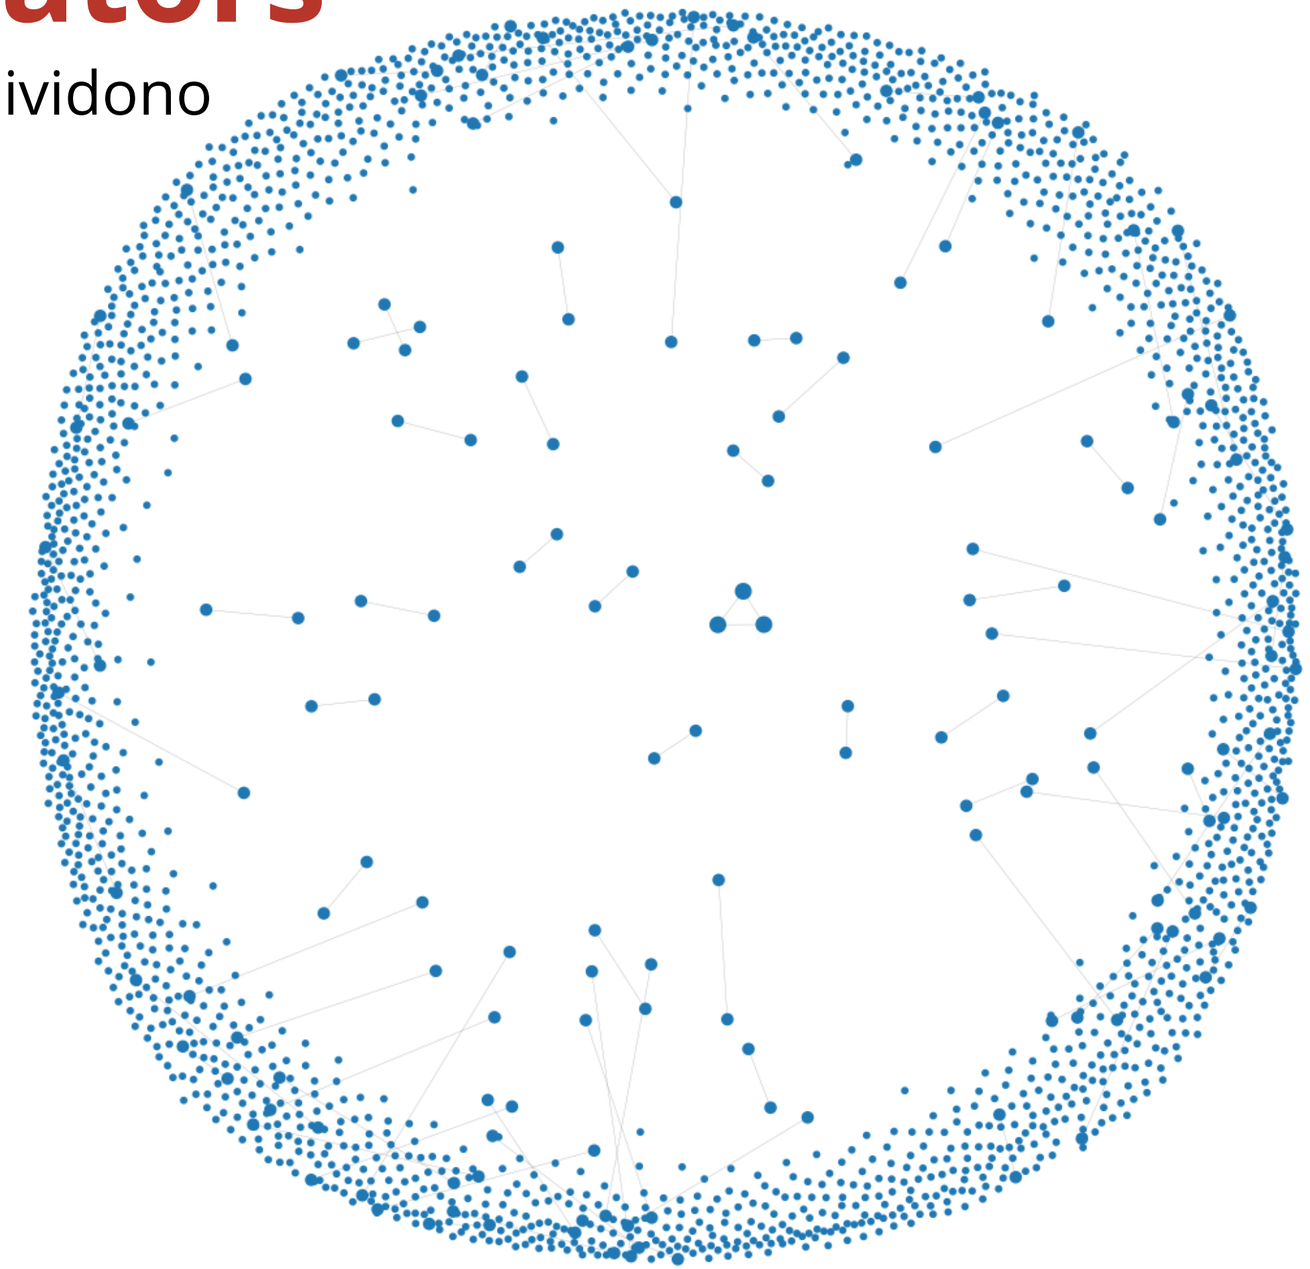
Tramite sottografi è decisamente **meno preciso**, tuttavia si è osservato come ad ogni incremento graduale del numero di nodi per sottografo l'esito delle metriche si avvicina a quello ottenuto nella rete campionata.

Proiezione sui Creators

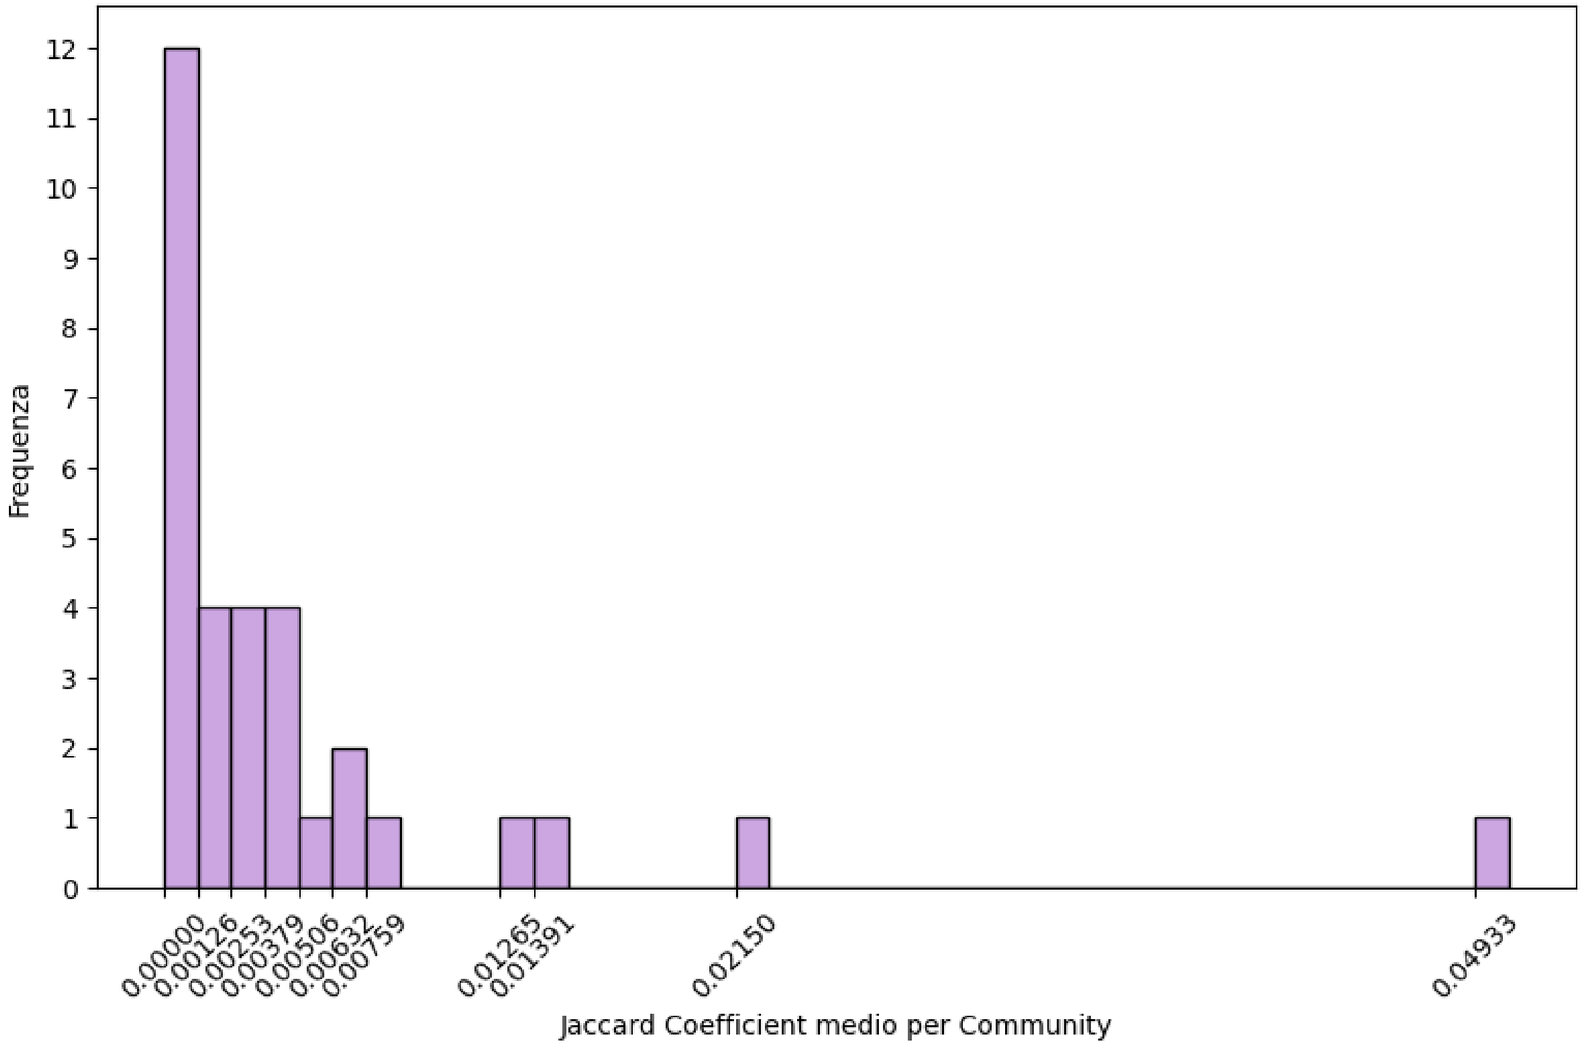
Un link tra i creators è presente se condividono almeno 400 commenters

NODI	**2032**
ARCHI	**83**
NODI ISOLATI	**1894**

Solo un numero molto limitato di creators (138) condivide una discreta porzione di audience.



Audience Overlapping nelle Communities



Creators NON appartenenti alla stessa Community

(media coefficenti jaccard):

0.00014

Media della distribuzione : **0.005**

Machine Learning

Dati due creators, in base alle loro metriche di Similarità basate sull'Audience, predizione di una futura collaborazione.

Metriche per ogni coppia di nodi (creators):

- **Jaccard Similarity**, intersezione / unione dei commentatori di ciascun creator.
- **Adamic Adar**, similarità tra creators considerando la rarità dei loro vicini comuni nella rete unipartita.
- **Preferential Attachment**, probabilità che due nodi formino un collegamento, basata sui loro gradi.
- **Resource Allocation**, similarità tra creators nella rete unipartita, dando maggior peso ai vicini comuni con meno connessioni.

Dataset

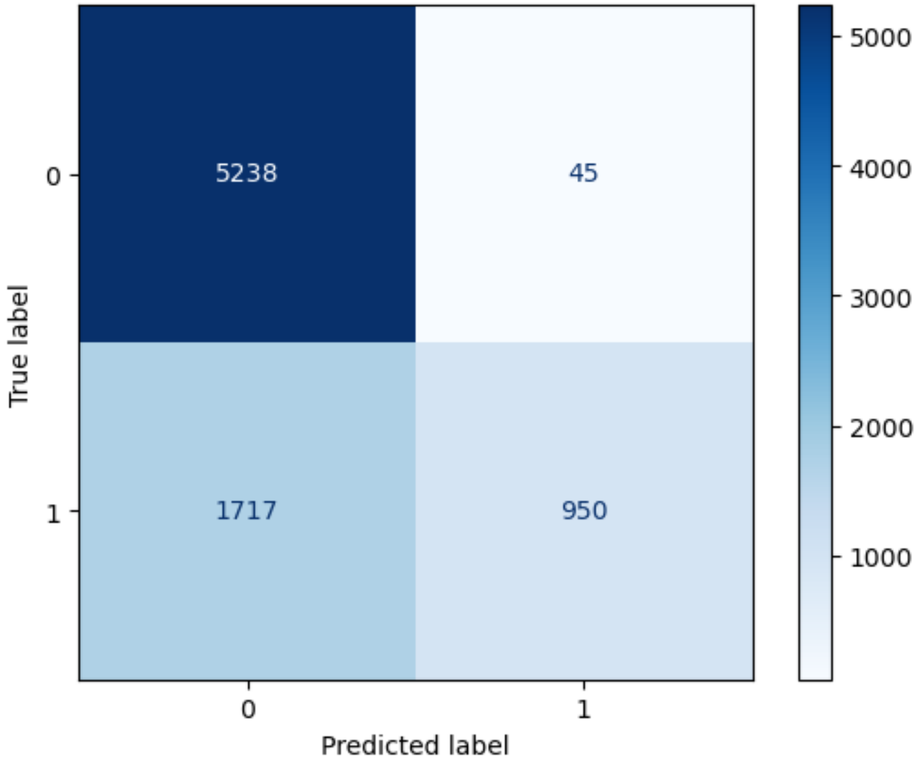
Unendo alle metriche per ogni coppia di creator la label della collaborazione nella **Collaboration Network** si ottiene il Dataset per il modello.

Molto sbilanciato, con solo lo **0,0025%** di record con Target = 1 (**5333/2 118 711**).

- Estratti i due sottoinsiemi di record delle rispettive classi.
- Dal sottoinsieme con Target = 0 sono stati ***scartati il 99.5%*** dei record.
- I rimanenti sono stati uniti con quelli con Target = 1. Arrivando ad una distribuzione più bilanciata tra le classi di **5333** e **10.566**.

Infine è stato eseguito lo split in Training e Test set.

Logistic Regression *vs* Random Forest

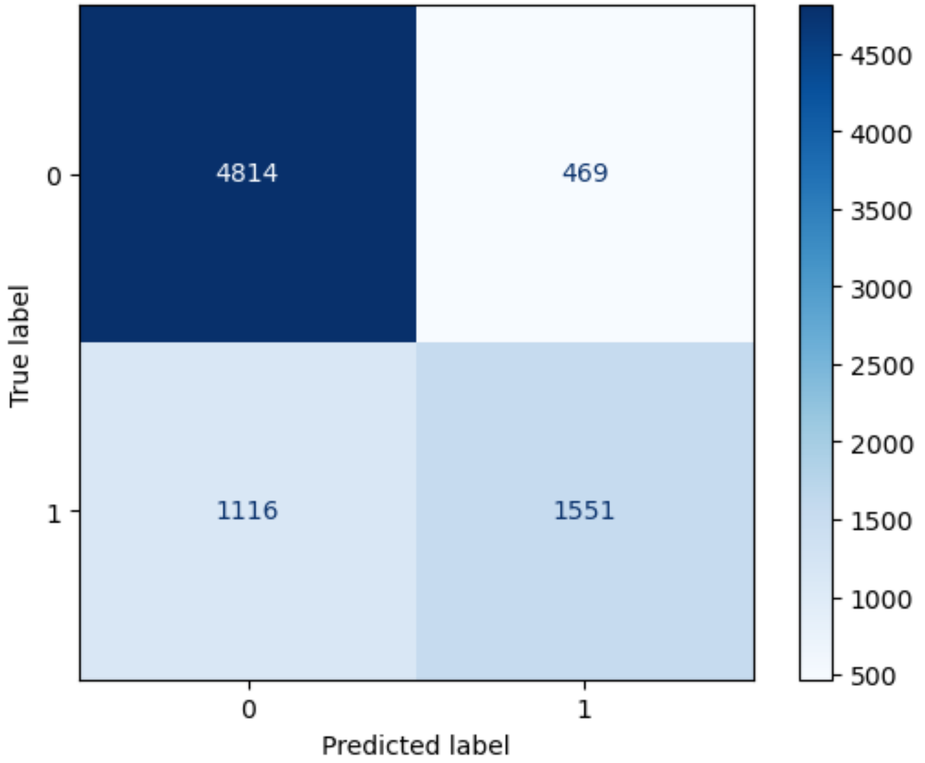


Accuracy: 0.78

Precision: **0.95**

Recall: **0.36**

F1: **0.52**



Accuracy: 0.8

Precision: **0.77**

Recall: **0.58**

F1: **0.66**

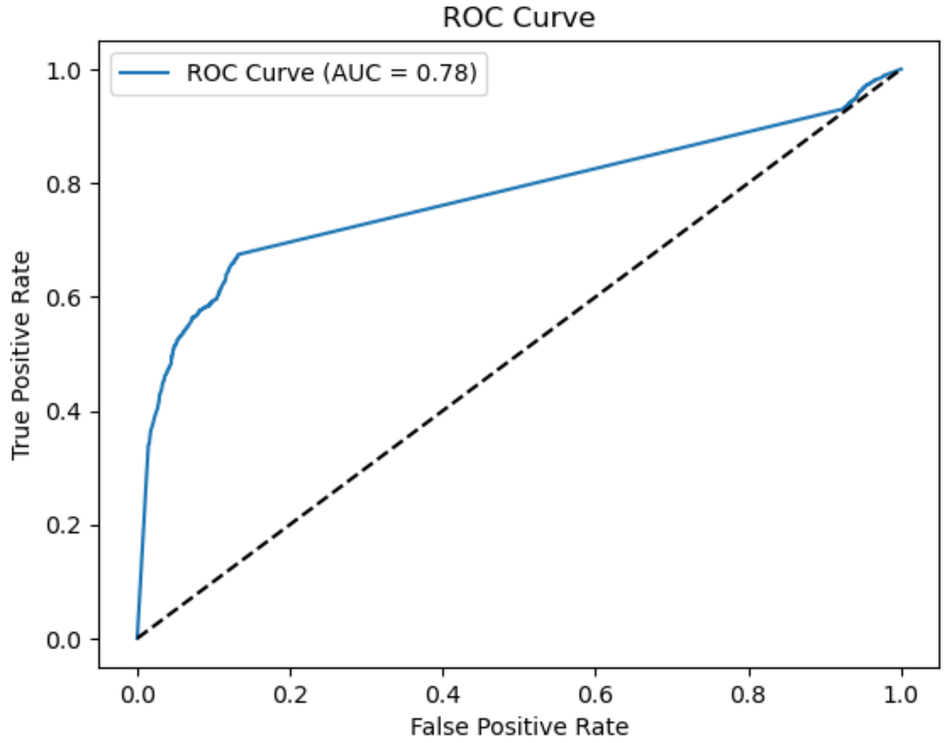
Random Forest - Ottimizzazione

La soglia ottimale basata sul F1-Score è: **0.24**

Utilizzando la soglia trovata queste sono le ***predizioni finali***:

- *Accuracy*: **0.80**
- *Precision*: **0.72**
- *Recall*: **0.67**
- *F1*: **0.70**

ROC-AUC Score di: **0.78**



Conclusioni

- La ***rete delle Collaborazioni*** è disassortativa, sparsa e disomogenea. Con pochi hub centrali molto connessi e la maggior parte dei creators con poche collaborazioni.

- L'analisi delle ***audience*** mostra una bassa sovrapposizione tra i creators, confermando che ciascuno tende a mantenere un pubblico distinto, con solo poche eccezioni.

- Il modello di ***machine learning*** ha dato risultati promettenti, nonostante il dataset sbilanciato, suggerendo che le metriche di similarità delle audience possono predire collaborazioni future, anche se c'è ancora spazio per migliorare soprattutto nel recall.

Possibili sviluppi futuri ...

- ***Approfondimento delle Collaborazioni Implicite***: Analisi semantica per identificare le collaborazioni implicite nei video.
  Riducendo la perdita di informazione e migliorando la qualità dei dati.

- ***Ampliamento dell'Audience Analysis***: Analizzare tutti i commentatori per ogni canale, senza i vincoli di questo progetto. Segmentando l’audience in base a caratteristiche demografiche o preferenze specifiche, utilizzando dati supplementari.

- ***Miglioramento dei Modelli Predittivi***: Includere modelli di deep learning o tecniche di apprendimento non supervisionato per aumentare la capacità del modello di identificare pattern latenti nelle collaborazioni.

- ***Estensione a diverse piattaforme***: Ad esempio Instagram o TikTok, per fornire una visione anche delle collaborazioni e audience cross-platform.